Poročilo projekta 2

XPath, regular expressions, Automatic Web extraction

Aljaž Rupar, Nal Lukšič, Gregor Ažbe

Opis spletne strani:

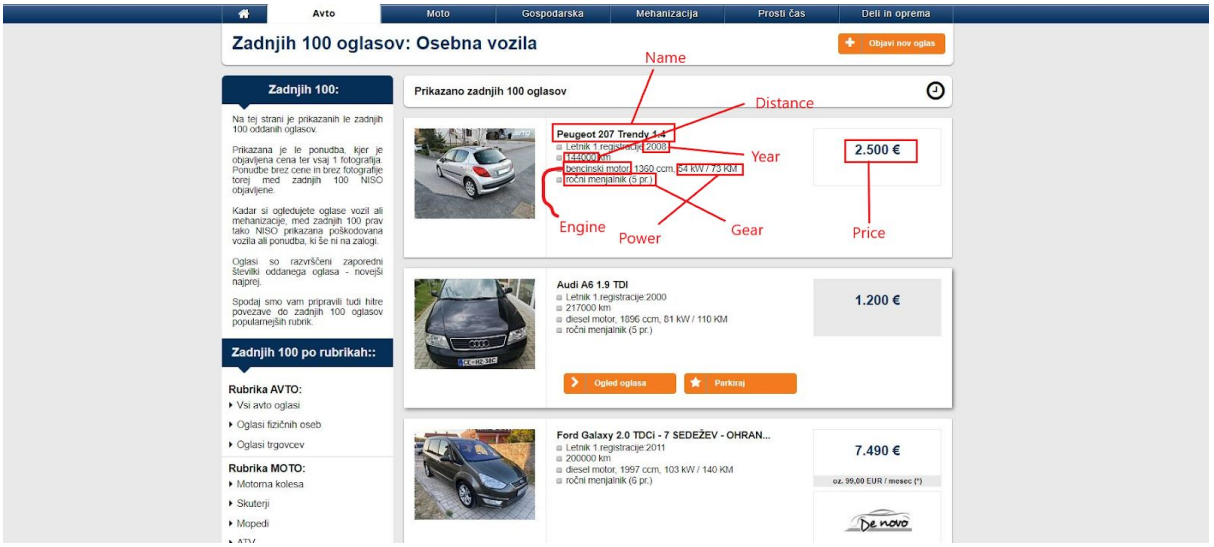

Automatic Web extraction

Psevdo koda:

```
Read both pages with BeautifulSoup using lxml
Delete tags like script, style, comments, iframe, link
Delete attributes of all tags
procedure generate_wrapper(html1, html2, wrapper):
  while(iterate trough both html):
    If(both Strings):
      If(same String):
        add string to wrapper
      If(different string):
        mark string miss match
    If(both same element of type Tag):
      add element to wrapper
      if(both have children):
        go recursive for all children
      else:
        if any has children, then add them to wrapper

    # Here is a miss match
    else:
      find next match in the other
      If(not found): # for both
```

```
                add element as optional
            else: # both found element
                add all skipped elements as optional
                continue on next match that matches sooner

        # one ends before other
        iterator -> check if iterator(repeating in same tag)
        If(iterator):
            add and mark as iterator
        else: # for both
            add as optional element
    end procedure

    print wrapper
```

Opis kode:

Pri implementaciji smo uporabili knjižnico BeautifulSoup. Potrebno se je bilo sprehoditi čez oba HTML dokumenta in izpisati ovojnico. Generiranje ovojnice je potekalo na način opisan v psevdo kodi. Pri implementaciji smo si pomagali s člankom, ki opisuje algoritem Road Runner.
Pravila, ki smo jih uporabili so sledeča:
Preverjali smo podobnost obeh HTML dokumentov s sprehajanjem po dokumentu v globino. Potrebno je bilo preverjati ali gre za html oznako ali za besedilo (NavigatableString ali Tag)
Vključili smo sledeče situacije:

a) Iste oznake in besedila smo dodali v ovojnico.
b) V primeru različnega besedila smo v ovojnici označili, da gre za besedilo na istem nivoju ter različnim besedilom. Oznaka za to je bila #Text.
c) V primeru različne oznake smo najprej preverjali če pride do ujemanja v nadaljevanju drugega dokumenta. V primeru neujemanja smo dodali element kot opcijski in nadaljevali na naslednjem elementu. V primeru ujemanja smo nadaljevali na enem, ki se konča prej kot drugi ter dodali vse ostale elemente, ki smo jih izpustili kot opcijske.
d) V primeru, ko se je eden izmed elementov končal prej kot drugi smo preverjali, če gre za iterator. To smo preverili z ujemanjem elementa v prejšnjih elementov v istem staršu. V primeru ujemanj smo elemente označili kot iteratorje in v nasprotnem primeru označili kot opcijske ter jih dodali v ovojnico.